

DI 그룹 특화 오픈소스 LLM 시스템



DI그룹 업무 활용 목적 오픈소스 LLM 모델 검토

모델별 성능·기능과 사내 PC 구축 가능성, 보안 대책 검토

TABLE OF CONTENTS


01. 검토 배경과 도입 방향
02. 모델 선정 기준
03. 모델 비교와 업무별 검토 대상
04. 필요 서버 사양 및 보안 대책

1. 검토 배경과 도입 방향

1. 검토 배경과 도입 방향

이전 실험에서 확인한 내용과 추가로 검토할 사항

업무에 필요한 성능을 갖추되, 운영 비용이 가장 적게 드는 모델 선정



2. 모델 선정 기준

2. 모델 선정 기준

모델 크기만으로 업무 적합성이나 최소 사양을 확정할 수 없음

현재 PC에서는 경량 모델부터 시험하고,
업무 성능을 확인한 뒤 대형 모델 채택 여부 결정

우선 시험

E2B·E4B·8B

문서 질의응답
기본 기능 확인

추가 비교

12B·26B A4B

품질 개선 폭과
응답 속도 비교

후순위 비교

30B·31B

멀티 모달 등 추가시 고려

별도 장비

109B·119B

별도 서버 필요시 검토

2. 모델 선정 기준

실제 업무에서 확인할 성능과 기능

답변 정확도·문서 검색

- I. 한국어 답변의 정확도
- II. 근거 문서와 페이지 제시 여부
- III. 근거 없는 답변의 발생 비율
- IV. 문서 간 내용 불일치 파악 여부
- V. 표·이미지 속 글자 인식 정확도
- VI. 요청한 답변 형식 준수 여부

자료 해석·외부 기능 실행

- I. 업무에 맞는 외부 기능 선택
- II. 실행에 필요한 정보 전달 정확도
- III. 여러 기능의 순차 실행 성공률
- IV. 지원하지 않는 기능의 요청 빈도
- V. 오류 발생 후 정상 처리 여부
- VI. 권한 없는 작업 차단 여부

처리 속도·운영 안정성


- I. 답변이 시작될 때까지의 시간
- II. 답변 완료 시간과 생성 속도
- III. 1·3·5명 동시 사용 시 성능
- IV. 서버 연산 장치·메모리 사용량
- V. 메모리 부족·응답 지연 발생
- VI. 설치와 장애 복구에 걸리는 시간

업무별 평가 기준을 먼저 정한 후, 같은 질문과 자료로 모델별 성능 비교

3. 모델별 성능 비교와 업무별 검토 대상

3. 모델별 비교와 업무별 검토 대상

Gemma 4 모델 규모와 4비트 메모리 참고값



출처: Google [G1-G2] | Q4_0 적재 참고값이며, 현재 PC의 총 메모리 사용량이나 처리 속도를 뜻하지 않음

3. 모델별 비교와 업무별 검토 대상

Gemma 4가 읽을 수 있는 자료와 주요 활용 업무

모델	텍스트	이미지	영상	음성	검토 업무
E2B	O	O	O	O	문서 검색 질의응답
E4B	O	O	O	O	문서 처리 기능 실행
12B	O	O	O	O	여러 자료 해석
26B A4B	O	O	O	-	복잡한 분석 업무 처리
31B	O	O	O	-	대형 모델 품질 비교

O는 입력 지원, 출력은 모두 텍스트. 영상은 장면별 이미지로 처리하며 실제 지원은 실행 프로그램에서도 확인 [G1]

3. 모델별 비교와 업무별 검토 대상

타사 모델 특징 및 사용 시 고려사항

Qwen3-VL 8B	Dense · 약 9B ¹	이미지·영상 해석·화면 작업	소형 모델의 자료 해석 비교
Qwen3-VL 30B-A3B	MoE · 약 31B / 활성 3B ¹	영상·글자 인식·기능 연동	중형 모델의 업무 처리 비교
EXAONE 4.5 33B	Dense · 33B	한국어·문서 처리·기능 연동	영리적 목적으로 사용 불가 업무 이용 전 허가 필요
Llama 4 Scout	MoE · 109B/활성 17B	여러 자료 유형 처리·기능 연동	한국어 공식 지원 X 대용량 장비 필요
Mistral Small 4	MoE · 119B/활성 6.5B	이미지·코드 작성·기능 연동	최대 성능·서버 부담 비교

출처: 각 개발사 [Q1·Q2·E1·L1·M1] | ¹ Qwen 전체 크기는 배포 페이지의 반올림 표기이며 모델명과 구분

3. 모델별 비교와 업무별 검토 대상

타사 모델의 입력·출력 지원 비교

모델	텍스트	이미지	영상	음성	출력
Qwen 8B	O	O	O	미기재	텍스트
Qwen 30B	O	O	O	미기재	텍스트
EXAONE 33B	O	O	미기재	미기재	텍스트
Llama Scout	O	O	미기재	미기재	텍스트
Mistral 119B	O	O	미기재	미기재	텍스트

공식 모델 카드의 명시 내용 기준. '미기재'는 불가능하다는 뜻이 아니며, 별도 처리가 필요한 지 확인 필요 [Q1·Q2·E1·L1·M1]

3. 모델별 비교와 업무별 검토 대상

업무별 비교 후보와 현재 사내 PC의 시험 대상

업무	업무별 비교 후보	현재 PC 시험 대상	초기 시험 목적
문서 검색·질의응답	E2B·E4B Qwen 8B·12B	E2B·E4B	검색 근거·답변 확인
문서 비교·보고서	E4B·Qwen 8B 12B·26B·31B	E4B	문서 내용 반영 확인
표·이미지·도면	E4B·Qwen 8B·12B 31B·EXAONE ¹	E4B·Qwen 8B ²	글자·수치 인식 확인
사내 시스템 조회	E4B·Qwen 8B 12B·26B	E4B·Qwen 8B ²	조회 기능 연결 확인
여러 단계 업무	12B·26B·31B Qwen 30B	E4B로 연결 확인	기능별 작동 확인
음성 입력	E2B·E4B·12B	E2B·E4B	음성 인식 확인

후보는 성능 순위 별 나열이며, 최소 사양이 아님. ¹ 사용 허가 확인 필요 ² 속도 확인 후 시험. 업무 적합성은 별도 평가

3. 모델별 비교와 업무별 검토 대상

업무 적합성 평가 항목과 현재 PC의 확인 범위

업무	후보 비교 목적	업무 적합성 평가	현재 PC 확인 범위
문서 질의응답	검색 자료에 근거한 답변 비교	정답·출처 응답 시간	소형 모델의 답변 품질·속도
보고서 작성	여러 문서의 내용 반영 비교	내용 누락 근거 없는 답변	E4B로 초안 작성 부족한 점 확인
표·도면 해석	이미지 속 정보의 인식 정확도 비교	수치·단위 도면 오독	간단한 표·이미지 인식부터 확인
시스템 조회	조회 요청의 정확한 실행 비교	조회 대상 전달 정보 정확도	조회 기능 연결 권한 확인
여러 단계 업무	여러 기능을 거치는 업무의 완료도 비교	중간 오류 권한 밖 실행	E4B로 연결 여부 점검
음성 입력	음성 내용의 인식 정확도 비교	인식 정확도 처리 시간	짧은 음성의 인식·속도 확인

같은 업무 자료로 비교한 뒤 도입 모델 결정

4. 필요 서버 사양 및 보안 대책

4. 필요 서버 사양 및 보안 대책

현재 사내 PC 사양과 구축 가능 범위

① 현재 사내 장비

CPU: Core Ultra 7
270K Plus
RAM: 32GB
별도 GPU 없음

업무용 PC를 활용:
CPU 실행을 기준으로 검토
저장공간·운영체제 확인 필요

② 우선 시험할 범위

E2B·E4B의 4비트 모델 비교:
문서 검색·질의응답부터 시작
처음에는 한 번에 1건 처리
짧은 문서와 답변으로 시험

추가 비교:
Qwen 8B·12B는 속도 확인,
상시 운영 적합성은 시험 후 판단

③ 증설 판단 기준

현재 장비에서 먼저 성능 확인:
메모리 부족·응답 지연 구분
문서량과 동시 요청을 단계적 확대

메모리가 부족하면 RAM 검토,
계산이 느리면 GPU 추가 검토,
장시간 운영은 전용 장비 검토,
장착·전력·냉각 조건 확인 필요

4. 필요 서버 사양 및 보안 대책

모델별 메모리 참고값과 현재 PC 적용 판단

모델	4비트 참고값	현재 PC 검토안	추가 장비 검토안
E2B / E4B	2.9 / 4.5GB ¹	우선 시험 CPU·RAM 32GB	속도 부족 시 GPU 검토
12B	6.7GB ¹	조건부 시험 응답 속도 확인	GPU 16GB급 RAM 32GB부터
Qwen 8B	약 4.5GB ²	조건부 시험 이미지 속도 확인	GPU 16GB급 RAM 32GB부터
26B / 31B	14.4 / 17.5GB ¹	후순위 비교 속도·메모리 확인	GPU 24~32GB급 RAM 64GB부터
Qwen 30B EXAONE 33B	약 15.5 / 16.5GB ²	후순위 비교 EXAONE 허가 확인	GPU 32~48GB급 RAM 64GB부터
Scout / Mistral	약 54.5 / 59.5GB ²	32GB에 전체 메모리 적재 불가	대용량 서버 별도 설계 필요

¹ 공식 문서 참조 ² 전체 규모×0.5바이트 계산값(부가 메모리 제외). 추가 장비는 시험 구성안이며 최소 보장 사양이 아님

사용자별 권한에 따라 문서 열람과 기능 실행 범위 제한

사용자	문서	네트워크	외부 기능 실행	운영
별도 계정으로 로그인, 승인된 사용자만 허용	검색할 때마다 권한 확인, 허가된 문서만 답변에 사용	사내망 접속, 통신 암호화	조회 기능부터 허용, 수정·발송 전 담당자 승인	이용 기록·백업 관리, 설치 파일과 업데이트 검토

4. 필요 서버 사양 및 보안 대책

허가된 DI그룹 사용자만 접속하는 구성안

1

사내 접속

허용된 사내망에서
암호화 된 화면 접속

2

사용자 확인

사내 계정 로그인
DI 승인 그룹 확인

3

권한 확인

문서·기능별 접근 확인
허가된 자료만 검색

4

답변·기록

모델은 내부에서 실행
답변 제공·이용 기록

계정이 있어도 이용 승인이 없으면 차단. 로그인·검색·문서 열람·기능 실행 단계마다 권한 확인 [S1·S2·S4]

4. 필요 서버 사양 및 보안 대책

현재 PC에서 성능을 확인한 뒤 도입 범위 결정

1

소형 모델 시험

E2B·E4B 우선 비교
같은 문서·질문 사용

2

필요 시 추가 비교

Qwen 8B·12B 검토
부족한 기능 중심 비교

3

운영·보안 확인

1건 처리부터 확대
응답 시간·권한 확인

4

도입 범위 결정

모델·장비 구성 결정
허가 사용자부터 적용

전체 모델을 현재 PC에서 일괄 시험하지 않고, 소형 모델의 부족한 점이 확인될 때 비교 범위 확대

4. 필요 서버 사양 및 보안 대책

종합 검토: 소형 모델의 제한적 운영부터 확인

① 현재 장비 활용

RAM 32GB·별도 GPU 없음,
E2B·E4B를 우선 비교,
문서 검색·질의응답부터 시험

기존 E2B 구동 확인을 기준으로
답변 정확도·속도를 추가 확인,
여러 명의 원활한 사용은 미확인

② 도입 전 보완

승인 사용자만 접속 허용,
문서·기능별 권한 적용,
응답 시간과 오류율 확인

운영 담당자와 이용 범위 결정,
사용 기록·백업 기준 수립,
일부 사용자부터 시범 사용

③ 확대 판단

성능이 충분하면 현재 장비 활용,
메모리 부족이면 RAM 확대 검토,
응답 지연이면 GPU 추가 검토

복잡한 업무는 12B 이상 비교,
26B를 필수 최소치로 단정하지 않음,
추가 사양은 시험 결과로 결정

부록

전체 파라미터(모델 규모)

모델을 구성하는 전체 수치의 개수

모델을 메모리에 올릴 때
필요한 용량을 계산하는 기준

유효 파라미터(E)

E는 유효 파라미터 표기
전체 크기와 구분

E2B: 유효 2.3B / 전체 5.1B
E4B: 유효 4.5B / 전체 8B

활성 파라미터(A)

답변 생성 시 실제 계산하는 부분

A4B로 표기해도 메모리에는
전체 모델을 올려야 함

일반 구조(Dense)

답변을 생성할 때 모델의 대부분을 계산에 사용

일부를 선택하는 구조(MoE)

일부만 계산에 사용하지만 전체 모델을 메모리에 올리는 구조

필요 메모리 = 모델 저장 용량 + 답변 생성용 임시 공간 + 동시 처리·입력 자료 용량

용어	쉬운 의미	검토할 사항
처리 자료 유형	글·이미지·영상·음성 등 모델이 처리할 수 있는 자료의 종류	읽을 수 있는 자료와 만들 수 있는 자료 구분
한 번에 참고하는 자료량	한 번 답변할 때 참고할 수 있는 글과 자료의 양	자료량이 많을수록 메모리 사용량·대기시간 증가
외부 기능 실행 요청	모델이 정해진 형식으로 사내 시스템 조회 등의 기능 실행을 요청	요청한 기능의 정확한 실행 여부
문서 검색 기반 답변	관련 사내 문서를 찾아 답변의 근거로 제공	열람 권한이 있는 문서만 검색
모델 용량 축소	모델의 수치를 더 적은 비트로 저장하여 메모리 사용량 절감	축소 후 답변 정확도·속도·정상 동작 확인

구분	확인한 공식 자료	반영 내용
[G1·G2] Google	Gemma 4 모델 카드·공식 실행 안내	모델 구조·지원 기능·메모리
[Q1·Q2] Qwen	Qwen3-VL 8B·30B-A3B 공식 모델 카드	전체 크기·입력 기능·출력
[E1] LG AI연구원	EXAONE 4.5-33B 공식 모델 카드	전체 크기·한국어·사용 조건
[L1] Meta	Llama 4 Scout 공식 모델 카드	전체·활성 크기·지원 언어
[M1] Mistral	Mistral Small 4 공식 모델 카드	전체·활성 크기·입력 기능

구분	확인한 공식 자료	반영 내용
[R1] llama.cpp	CPU 실행·모델 용량 축소 공식 안내	현재 PC의 실행 방식 검토
[S1] OWASP	사용자 권한 검증 지침	승인 사용자·문서 권한 확인
[S2] OWASP	통신 암호화 지침	사내 접속 구간 암호화
[S3·S4] OWASP	악성 지시 대응·외부 기능 권한 제한	자료 속 지시·변경 작업 통제
장비·기존 결과	사용자 제공 사내 PC 사양 및 기존 보고서	RAM 32GB·별도 GPU 없음

실제 처리 속도·동시 사용자 수는 미측정. 추가 장비 구성과 보안 운영 방식은 DI그룹 적용 제안

감사합니다.