

뉴엔AI 특화 오픈소스 LLM 시스템



구축 가능성 검토를 위한 탐색적 조사 및 테스트

3차 보고서
Gemma 4 api와 Docker를 활용한
서버 운영 테스트

TABLE OF CONTENTS

01. 인프라 요구사항

02. 구축 계획

03. 수행 범위 및 테스트 결과

04. 정리

1. 인프라 요구사항

적용 방안	적용 의도
Gemma 4 E2B Q4 모델 사용	경량화 된 모델로 CPU와 32GB RAM에서도 구동 가능
답변 길이 제한	핵심 내용 중심으로 답변 길이 를 제한하여 CPU 사용시간과 전체 대기시간을 단축
질문 대기열 적용	여러 질문이 한꺼번에 들어오면 순서대로 처리 하는 방식을 차용하여 CPU와 메모리의 과부하를 방지하고 서비스가 중단되는 상황 방지
동일·유사 질문은 기존 답변 재활용	반복되는 질문마다 검증된 기존 답변 을 재사용 (시스템 프롬프트에 가이드라인 형식으로 명시)하여 응답시간과 CPU 사용량 절약
파인튜닝 시 가상 GPU 활용	모델 학습 시 Runpod와 같은 종량제 가상 GPU 서비스 를 이용하여 GPU 장비를 직접 구매하지 않고 파인튜닝 수행

40명 규모 운영을 위한 초기 권장 사양

구성요소	최소 사양	이유
CPU	24~32코어	답변 생성, 문서 처리와 검색 작업 분담
RAM	128GB	모델·검색 DB·운영 서비스의 작업공간 확보
저장장치	NVMe SSD 2TB	원본, 변환본, 검색 DB와 백업 전 임시 저장본 저장
네트워크	사내 1Gbps 이상	40명 웹 접속과 문서 전송
운영체제	Linux 서버	장시간 운영 및 Docker 관리
백업	별도 2~4TB	원본과 검색 DB 복구용
동시 질문 처리 수	3~5건	CPU 전용 서버 구축을 전제했을 때, 동시에 처리 가능한 질문의 수

※ 상기 사양은 사용자 40명, 동시 질문 3~5건을 가정한 것이며,
최종 사양은 실제 문서 규모와 실제 사용환경 세팅 후 테스트한 결과에 따라 확정

방식	운영 방식	장점	한계	적합한 용도
클라우드 CPU 서버	클라우드에 서버를 만들고 Gemma·RAG·API를 운영	장비 구매 없이 CPU·RAM·저장공간을 쉽게 확장할 수 있음	매월 비용 발생, CPU 기반으로 답변 속도에 한계	개발·소규모 운영, 40명 접속 환경 부하 실험
클라우드 GPU 서버	GPU가 장착된 서버를 필요한 기간에만 임대 (GPU 모델 별 가격 상이)	파인튜닝과 대규모 데이터 처리를 빠르게 수행	장시간 실행 시 비용 증가	파인튜닝, 대량 문서 처리, 모델 성능 비교
하이브리드	문서·RAG·업무 관련 답변은 사내 서버에서 처리하고 학습과 고부하 작업만 클라우드 사용	보안과 비용의 균형을 확보하고 GPU 구매 비용을 최소화	사내 시스템과 클라우드의 연결 및 데이터 관리 기준 설정 필요	이번 프로젝트의 우선 검토안

평상시 운영은 사내 CPU 환경에서 수행하고, 파인튜닝과 대규모 데이터 처리에만 클라우드 GPU를 일시적으로 사용하는 하이브리드 구조가 가장 적합


가상 GPU는 상시 운영 서버가 아니라 파인튜닝과 고부하 작업에만 단기간 사용하고,
작업 완료 후 결과 모델을 사내 CPU 서버로 이전하는 방식으로 활용

공급자	GPU 컴퓨팅 서비스	비용 절감 방식	서비스 특징	활용 가능성
네이버클라우드	GPU Server	상품별 과금 조건 확인	다양한 NVIDIA GPU 서버 제공, 국내 서버로 낮은 지연시간	국내 클라우드 환경에서 파인튜닝 및 대규모 문서 처리
AWS	EC2 GPU 인스턴스 (G4dn 등)	EC2 Spot 선택 가능 (Spot 방식: 남는 클라우드 자원을 할인된 가격으로 이용하는 방식, 작업 도중 서버가 종료될 수 있어 중간 결과를 저장할 수 있는 작업에 적합)	NVIDIA T4 기반으로 추론과 소규모 학습에 활용 가능	Gemma 추론, LoRA·QLoRA 시험 및 일괄 데이터 처리
Google Cloud	Compute Engine GPU (L4·A100·H100 등)	Spot VM(Virtual Machine) 구성 가능	작업 규모에 맞는 GPU를 가상 서버에 추가하여 사용	파인튜닝, 성능 비교 및 대규모 데이터 처리
Microsoft Azure	GPU VM	Azure Spot VM 등 검토 가능	GPU 가상 서버 제공, Microsoft 계정· 보안체계와 연계 가능	파인튜닝, 대량 문서 처리 및 사내 Microsoft 환경 연계
Runpod.io	GPU Pod· Serverless GPU	필요한 시간만 실행	GPU 작업에 특화된 서비스로 다양한 GPU를 비교적 간편하게 임대	단기 파인튜닝, 대규모 문서 처리 및 모델별 성능 비교

※ 외부 클라우드 서비스 이용시
비식별화 된 학습 데이터 필요 여부와 데이터 반출저장·삭제 기준 확인 필요

2. 파일럿 테스트용 시스템 구축

현재 PC 환경: 기능 검증과 소규모 파일럿까지는 가능



RAG 구축 후 서버 연결, 테스트까지 진행



3. 시스템 구현 및 테스트 결과

03. 시스템 구현

홈페이지 구성

질문

휴직원은 언제까지 작성해야 하나요?

1. 질문 쿼리 입력

검색할 근거 수

5

2. 검색 문서 수 설정
답변 근거로 탐색할 문서의 수 설정

질문하기

답변

휴직원은 휴직 시작 30일 전까지 작성해야 합니다 [근거 1 | p.24].

3. 답변 및 출처 표시
답변과 함께 참고한 문서와 페이지를 표시,
Score은 가장 일치하는 문서일수록 점수가 높게 표시

검색 근거

page	title	score
24	3. 전자문서 작성방법 - 인사 - 휴직원 기안서	0.1532
4	페이지 4	0.1305
51	3. 전자문서 작성방법 - 품의 - 품의서_일반	0.1197
48	3. 전자문서 작성방법 - 품의 - 지출결의품의서	0.1191
19	3. 전자문서 작성방법 - 인사 - 복리후생_경조사비 품의서	0.1177

전체 처리시간

5.36초

4. 전체 처리시간
질문 전송부터 문서 검색, 답변 생성,
화면 표시 완료까지 소요된 총 시간

Gemma 생성 속도

39.7 token/s

5. Gemma 생성 속도
답변 문장을 만들어 내는 속도

※ 단일 사용자·단문 질문·검색 문서 5개·해당 PDF 데이터 기준 1회 측정값

03. 시스템 구현

시스템 테스트 결과

사내 네트워크에 홈페이지 생성 후 url 공유,
접속 후 기능 테스트 진행, 접속 가능 여부 확인

질문

휴직원은 언제까지 작성해야 하나요?

검색할 근거 수

5

질문하기

답변

휴직원은 휴직 시작 30일 전까지 작성해야 합니다 [근거 1 | p.24].

검색 근거

page		title	score
24	3. 전자문서 작성방법 - 인사 - 휴직원 기안서		0.1532
4	페이지 4		0.1305
51	3. 전자문서 작성방법 - 품의 - 품의서_일반		0.1197
48	3. 전자문서 작성방법 - 품의 - 지출결의품의서		0.1191
19	3. 전자문서 작성방법 - 인사 - 복리후생_경조사비 품의서		0.1177

전체 처리시간

5.36초

Gemma 생성 속도

39.7 token/s

예시 질문

자기계발비 지원 대상과 금액을 알려줘

질문

자기계발비 지원 대상과 금액을 알려줘

검색할 근거 수

5

질문하기

답변

자기계발비 지원 대상과 금액에 대한 정보는 다음과 같습니다.

자기계발비

- 지원 대상: 3개월 이상 재직자(임원 제외) [근거 2]
- 지원 내용: 연간 50만원 [근거 2]
- 지원 범위: 자격증, 취미, 운동 등 자기계발을 위해 사용한 금액 (음주거부 제외) [근거 2]
- 사용 기간: 1월 1일 ~ 12월 31일 (이월 불가) [근거 2]

자기계발비 품의서 관련 참고 사항

- 증빙은 반드시 "일반영수증"을 선택해야 하며, 공금가액에 전액 기입하고 계정과목은 자기계발비로 선택해야 합니다 [근거 1].
- 첨부파일로 영수증을 첨부하면 실물 영수증 제출은 불필요합니다 [근거 1].

기타 복지 관련 지원 내용

좌: 104번 PC / 우: 103번 PC 접속 화면.
페이지 접속 및 정상 구동 확인

4. 정리

성과

- I. CPU 기반 Gemma 4 기반 시스템 구축 성공:
추후 시스템 구체화 시 활용 가능한 기본 프레임워크 확보
- II. 사내 네트워크 내 홈페이지 배포:
오픈 소스 LLM 기반 사내 특화 LLM 배포 가능성 확인
(단, 정식 운영을 위해서는 사용자 인증, 접속 관리,
장애 대응 및 동시에 여러 사용자가 접속한 후 추가 테스트 필요)

수치 해석

- I. 답변 완료까지 5초 이상 소요:
개인 및 5명 미만 사용자는 원활하게 사용이 가능하지만,
DI 그룹 (40명 상당) 전체 사용 시
답변 대기 시간이 크게 증가할 것으로 예상
- II. 답변 생성 속도 39.7 tokens/s 의 의미:
단일 사용자 환경에서는 정상적인 답변 생성이 확인되었으며,
소수 사용자의 이용 가능성도 확인완료
동시 사용자 수에 따른 성능 변화는 별도의 테스트 필요

RAG 문서 규모 확대, 더욱 복잡한 쿼리 처리 대응 방안 모색

01

자료 및 질문 난이도 확대

현재: CPU 기반 시스템
구동 확인을 위해
용량이 작은 문서와
단문으로 구성된 질문을 사용

향후 목표: 문서 크기와 종류를
늘리고, 여러 자료를 비교하고
판단하는 복잡한 질문으로
답변 정확도와 처리시간 확인

02

에이전트 구조 구현

자료 종류와 질문의 종류가
늘어나는 상황에 대비하여

질문의 내용과 목적을 구분하여
RAG 검색, 일반 답변 등
적절한 처리 방식을 선택하는
에이전트 구조를 구축하고,
정확도와 처리시간을 비교 검증

03

하이브리드 구조 구축

최신 정보와 근거는 RAG 문서에서
찾고,

반복되는 업무 방식과 사내에서
통용되는 용어와 표현은
파인튜닝을 통해 모델에 반영하여
사내 맥락에 적합한 답변을
제공하는 구조 구축

04

테스트

40명 규모의 실제 사용 환경에서
답변의 정확성, 업무 활용도와
대기시간을 측정하고,

기존 장비로 안정적인 운영이
가능한지 검증

감사합니다.